

人工智能在头影测量自动定点算法上的研究进展

汪云毅^{1,2} 朱珠^{2,3,4} 张峰^{1,2}

1. 浙江大学医学院附属儿童医院口腔科 杭州 310000;
2. 国家儿童健康与疾病临床医学研究中心 杭州 310000;
3. 浙江大学医学院附属儿童医院数据信息部 杭州 310000;
4. 浙江-芬兰儿童健康人工智能联合实验室 杭州 310000

[摘要] 头影测量是正畸诊断和治疗过程中不可或缺的分析手段。高精度定位头影测量的标志点对于确保正畸临床诊断的准确性和治疗目标的正确性至关重要。随着计算机辅助技术特别是人工智能的发展,头影测量标志点从手动标注逐渐进展到自动定点,并已应用于临床实践。从基于知识方法到基于模型和模板匹配方法,再到现在的机器学习及深度学习方法,人工智能在传统头颅侧位片上标志点检测的准确率已有显著提高,但在图像数据更精确的三维图像上,自动定点尚处于起步阶段。本文旨在综述人工智能在头影测量自动定点算法方面的研究进展,并对其未来研究方向进行展望。

[关键词] 人工智能; 头影测量标志点; 自动定点; 机器学习; 深度学习; 自动化分析; 计算机视觉

[中图分类号] R783.5 **[文献标志码]** A **[doi]** 10.7518/gjkq.2024061



开放科学(资源服务)
标识码(OSID)

Progress of research on using artificial intelligence for cephalometric automatic-landmarking algorithms

Wang Yunyi^{1,2}, Zhu Zhu^{2,3,4}, Zhang Feng^{1,2}

1. Dept. of Stomatology, Children's Hospital, Zhejiang University School of Medicine, Hangzhou 310000, China; 2. National Clinical Research Center for Child Health, Hangzhou 310000, China; 3. Dept. of Data and Information, Children's Hospital, Zhejiang University School of Medicine, Hangzhou 310000, China; 4. Sino-Finland Joint AI Laboratory for Child Health of Zhejiang Province, Hangzhou 310000, China

Supported by: Grants from "Pioneer" and "Leading Goose" Research and Development Program in Zhejiang Province (2023C03101)

Correspondence: Zhang Feng, Email: zfwl@zju.edu.cn

[Abstract] Cephalometry is an indispensable tool in the diagnosis and treatment process of orthodontics. The high-precision localization of cephalometric landmarks is crucial to ensuring the accuracy of clinical orthodontic diagnosis and the correctness of treatment objectives. In clinical practice, doctors usually need to manually annotate these landmarks, which is time consuming and subjective. Over the past few decades, the concept of automated cephalometric landmark identification has emerged with the development of computer-assisted technology, particularly artificial intelligence. This automated identification is gradually being applied in clinical practice. From the knowledge-based method to the model-based and template-based matching method, and subsequently to the current machine-learning and deep-learning methods, the accuracy of artificial intelligence in landmark detection on traditional lateral cephalogram has significantly improved. However, in three-dimensional images with more accurate image data, automatic landmarking remains in its infancy. This article aims to review the progress of research on artificial intelligence in automatic-landmarking algorithm for cephalometry, as well as to look forward to its future research directions.

metry, as well as to look forward to its future research directions.

[Key words] artificial intelligence; cephalometric landmarks; automatic landmarking; machine learning; deep learning; automated analysis; computer vision

[收稿日期] 2023-12-10; **[修回日期]** 2024-04-12

[基金项目] 浙江省科学技术厅“尖兵”“领雁”研发攻关计划(2023C03101)

[作者简介] 汪云毅,住院医师,硕士,Email: 22118765@zju.edu.cn

[通信作者] 张峰,主任医师,博士,Email: zfwl@zju.edu.cn

自1931年Broadbent和Hofrath提出头颅X线摄影以来,已经开发了众多头影测量分析方法^[1]。这些方法使得正畸医生能够对患者的颅面部骨骼、牙列、软组织进行细致分析,从而作出准确诊断并制订治疗计划。头影测量中,标志点的高精度定位对于确保正畸临床诊断和治疗目标的正确性至关重要。不同的头影测量方法需要不同的标志点,一些复杂的分析方法可能涉及数十甚至上百个标志点。医生会根据经验选择合适的分析方法,以确定所需的标志点。传统的头影测量分析通常在特制绘图纸上进行,通过量角器和尺子来测量角度和距离,以获取患者的正畸相关数据,帮助医生诊断和制订治疗计划。随着计算机辅助头影测量软件(例如Dolphin Imaging)的推出,医生能够在计算机上标注头影测量标志点,软件则自动计算相关的测量值(角度值、距离值),简化了计算步骤。尽管如此,这一工作仍旧会耗费医生大量时间,并易受操作者本身的经验和水平等主观因素的影响。

自20世纪90年代以来,越来越多的学者提出采用人工智能(artificial intelligence, AI)方法自动检测头颅侧位影像中的解剖标志点以实现自动化定点。目前, AI自动定点的平均径向误差(mean radical error, MRE)为1 mm左右^[2],但对于2 mm成功检测率(successful detection rate, SDR),仍有部分标志点的定点误差与临床要求存在差距,需要医生进行手动调整。近年来已有多款商业化的AI辅助头颅侧位X线片定点软件系统应用于临床,如UCeph、智贝云等等,显著提高了工作效率^[3-6]。传统的二维X线片将头颅两侧结构重叠会产生放大或失真效果,锥形束计算机断层扫描技术(cone beam computed tomography, CBCT)应运而生。与传统计算机断层扫描技术(computed tomography, CT)相比, CBCT具有成本低、体积小、分辨率高、辐射剂量低等优点,已在口腔研究领域得到了广泛应用。相较于二维头影测量,三维头影测量尚处于起步阶段。目前AI在自动定点算法方面仍存在诸多挑战,如数据的缺乏、模型稳定性和泛化能力仍有待加强。本文对AI在头影测量自动定点算法的研究进展进行综述,并对其未来研究方向提出展望。

1 AI的提出和发展

AI一词由被誉为AI之父的约翰·麦卡锡于

1955年提出,用来描述机器执行智能任务的能力^[7]。目前, AI技术已广泛应用于口腔医学各个领域,其中头影测量标志点的定位是一个研究热点^[8]。在以往的研究中,学者尝试采用基于知识、基于模型以及模板匹配的方法进行自动定点,但效果并不理想。自2010年起,在大型数据集、快速且大规模并行计算、存储硬件(如图形处理器和超级计算机)以及新算法的推动下, AI的性能得到显著提升^[9]。目前流行的AI方法主要分为两类:机器学习(machine learning, ML)和深度学习(deep learning, DL)^[10]。基于样本数据(训练数据),通过ML算法生成数学模型,如支持向量机和随机森林,这些模型能够泛化特定模式以预测决策,而无需进行特定任务的显式编程^[11]。ML算法的架构灵感源自人类大脑中的生物神经网络,由各种人工神经元相互连接形成一个分层组织的网络。在第一层(输入)和最后一层(输出)之间,存在一定数量的(至少1个)隐藏层,负责AI的决策制定。所需的隐藏层数(深度)取决于训练任务的复杂程度。DL是指具有3层或更多隐藏层的算法。与传统ML相比, DL自动化了大部分特征提取过程,减少了人工干预,并允许处理更大的数据集。Schwendicke等^[12]对DL在头影测量标志点自动检测的准确性进行meta分析,发现DL在头颅侧位片标志点定位上具有较高的准确率。目前在正畸领域应用较多的DL算法是卷积神经网络(convolutional neural network, CNN)及其变体^[13],其隐藏层数量众多,结构更为复杂,由多个卷积层、池化层、激活层和全连接层组合而成,通过各种变换实现数据增强、降低计算复杂度,以提高泛化能力。

2 头颅侧位片自动定点

2.1 公共数据集

目前,有关头颅侧位X线片的一个主要公共数据集源自2015年国际生物医学影像国际研讨会(International Symposium on Biomedical Imaging, ISBI)举办的头影测量标志点自动检测挑战赛所提供的公开数据集^[14]。该数据集包含400张年龄为6~60岁患者的头颅X线片,每张图片的分辨率为(1 935×2 400)像素,每张都由2名经验丰富的医生手工标记了19个标志点。数据集被划分为不同部分,其中150张作为训练集,150张作为测试集1,剩余的100张则构成测试集2。

2.2 基于知识的方法

基于知识的方法是最早应用于头颅侧位X线片自动定点的方法,它结合了图像增强和边缘检测技术以及明确的解剖学知识来确定标志点位置。这种方法的准确率受图像质量的影响较大,并且只能检测边缘的标志点,因此未能在临床上得到应用,不过它为自动定点技术的发展迈出了第一步。1986年Lévy-Mandel等^[15]采用滤波和边缘检测器处理原始图像,而后提取相关边缘并利用先验知识进行边缘线追踪,识别定位了23个标志点,但精度不高。Parthasarathy等^[16]加入多分辨率金字塔以缩短识别时间,在较小、较低分辨率的图像上提取特征,对5张头颅侧位片进行测试,在2 mm的精度内定位9个标志点中的4个。Desvignes等^[17]进一步研究,提出了“三步法”,先使用自适应坐标空间粗略估计标志点,然后在周围计算感兴趣区域(region of interest, ROI),最后用解剖学定义精确定位,对鼻腔区域进行3个标志点的定点,误差约4.5 mm。

2.3 基于模型的方法

为了解决上述问题,学者们提出了一系列研究,侧重于使用某个标志点周围的局部外观。基于模型的方法在一定程度上适应图像比例、旋转、平移等变化,从而适应形状的变化。然而,这种方法的精确度容易受到图像分辨率、标志点可变性以及侧位片上类似结构的影响,并且需要一定的初始化过程。单独的基于模型的方法无法直接应用于临床,因此目前多采用与其他方法结合的方式形成新算法,以提高精确度。Hutton等^[18]采用主动形状模型(active shape model, ASM),虽然2 mm内SDR仅35%,但在一定程度上能够节省时间,并为后续研究提供了框架。Vucinić等^[19]提出一个基于主动外观模型(active appearance model, AAM)的系统,该系统结合了感兴趣对象形状和灰度外观的统计模型,并代表模型所覆盖区域的形状和纹理变化,17个标志点MRE为1.68 mm,仍远低于手动识别的精确度(87%)。

2.4 基于模板匹配的方法

基于模板匹配的方法是从基于模型的方法演变而来的。该方法通过改进初始近似位置的方式来提高准确率^[20],但随之而来的是更高的计算复杂性。当标志点数量增多时,精确度将明显下降。Cardillo等^[21]使用基于灰度形态学的模板匹配方法来直接识别标志点,在对40张侧位片的测试中,20个标志点中85%的标志点精度在2 mm之内。此

外, Grau等^[22]利用边缘检测器确定重要结构的位置,随后利用模板匹配寻找每个标志点的精确位置,17个标志点检出率超过90%。

2.5 基于ML的方法

国际生物医学影像国际研讨会在2014年与2015年举办了2届头影测量标志点自动检测挑战赛,其中基于ML的标志点自动检测方法开始显现其潜力。这些方法通常从局部图像中提取手工特征来训练分类器,以识别像素中心是否靠近标志点。与之前的方法相比,这标志着重大的进步,但2 mm SDR仍未能达到令人满意的水平。2015年ISBI挑战赛冠军Lindner等^[23]使用随机森林算法对局部外观进行分类,并使用统计形状模型来捕捉空间关系,在Test 1中MRE为 (1.67 ± 1.65) mm, 2 mm SDR为74.95%。与前者不同, Urschler等^[24]开发了一种整合几何形态和图像外观信息到统一随机森林框架中的标志点定位方法,在ISBI2015公开数据集上测试, 2 mm SDR为80.21%。随着DL的发展,学者开始更广泛地采用DL算法框架来实现自动定点。

2.6 基于DL的方法

2.6.1 区域提议分类 这种模式构建了一个基于CNN的框架,用于学习解剖标志点上的区域提议特征,并以此对标志点进行分类,然后通过综合区域提议进行定位。2017年, Arık等^[25]将CNN用于侧位片的自动定点。该CNN模型由4个卷积层、6个激活层、3个池化层和1个全连接层组合而成。通过学习输入图像块是否为标志点的概率,结合统计形状模型来细化所有标志点的最佳位置,在ISBI2015公共数据集上测试, Test 1中2 mm SDR为75.37%, Test 2中2 mm SDR为67.68%。Qian等^[26]提出了基于更快速的区域卷积神经网络(faster region-based convolutional network, Faster R-CNN)的头颅标志点检测方法,先根据训练数据中的标志点分布构造二维无向图,而后采用“最大置信度”选择标志点中的最佳点,对未检测到的标志点利用拉普拉斯变换进行修复, 2 mm SDR为82.5%。不同于传统CNN网络, Dai等^[27]提出一种基于生成对抗网络(generative adversarial networks, GAN)的头影测量自动定点方法,该方法中,一方面训练生成器生成输入源图像的距离图,另一方面训练判别器判定生成结果是否可被视为真实结果,两者通过循环博弈进行学习。该方法旨在从特征到特定目标距离图的映射,来预测所有标志点的距离图,最后通过类似回归投票

的方法定位,然而在学习过程中为减轻计算负担,损失了部分上下文信息,导致精确度有所下降。

2.6.2 坐标回归 这种模式使用与区域提议数量相匹配的基于CNN的多个回归模型来预测所有标志点的 x 和 y 坐标,该方法虽简单易于理解,并利用了标志点的结构知识,但计算量大,需要含有许多网络参数的致密层来模拟高度非线性,可能导致过拟合问题。Lee等^[28]开发了一个基于CNN的坐标回归系统,将19个标志点的 x 、 y 坐标视为38个独立变量,构建38个系统训练数据集,通过配对回归组合坐标形成19个标志点。该方法操作简单,标志点虽不完全与真实值匹配,但总体位于真实值边缘内。Gilmour等^[29]通过对多尺度图像块中每个标志点的相对位移进行从粗到细的回归来进行预测,但未考虑标志点之间的空间关系。在ISBI2015公共数据集上测试,Test 1中MRE为 (1.01 ± 0.85) mm,2 mm SDR为88.32%,Test 2中MRE为 (1.33 ± 0.74) mm,2 mm SDR为77.05%。Li等^[30]提出了一种将局部信息和全局形状相结合的拓扑适应深度图学习的方法,在ISBI2015公共数据集上测试,Test 1中MRE为1.04 mm,2 mm SDR为88.49%,Test 2中MRE为1.43 mm,2 mm SDR为76.57%。针对数据量有限的问题,Zeng等^[31]使用3个独立的回归步骤来估计头颅标志点的位置,并在每个步骤采用缩放、平移和亮度调整等数据增强方法,充分利用有限数据,在ISBI2015公共数据集上进行测试,Test 1中MRE为 (1.34 ± 0.92) mm,2 mm SDR为81.37%,Test 2中MRE为 (1.64 ± 0.91) mm,2 mm SDR为70.58%。

2.6.3 热图回归 这种模式通常用一个固定方差的高斯函数来编码一个标志点的伪概率,预测热图中的高响应作为标志点的位置,准确率较高。Payer等^[32]提出基于空间配置CNN的热图回归的方法,将一个组件专用于提供局部准确但可能有歧义的候选预测,而另一个组件则专注于结合空间配置,通过消除歧义来提高对标志点错误识别的鲁棒性,减少了对大型数据集的依赖,在ISBI2015公共数据集上测试,2 mm内的准确性更高。Zhong等^[33]提出了一个两阶段的U-Net方法^[34],其中全局阶段预测粗略位置,而局部阶段识别地标的精细位置,在ISBI2015公共数据集上测试,Test 1中MRE为 (1.12 ± 0.88) mm,2 mm SDR为86.91%,Test 2中MRE为 (1.42 ± 0.84) mm,2 mm SDR为86.06%。不同于前者,Kim等^[35]提出使用级

联CNN的方法,先提取ROI,然后利用U-Net识别ROI内标志点位置,对10个中心共3 150张侧位片测试20个标志点,MRE为 (1.36 ± 0.98) mm。相似地,Kwon等^[36]提出了一种多阶段定位方法,先通过训练一个能产生所有标志点热图的CNN来估计位置,而后对输入图像进行高分辨率裁剪并细化,最后应用线性滤波器进一步细化下颌骨双侧标志点的位置,在ISBI2015公共数据集上测试,Test 1中MRE为1.12 mm,2 mm SDR为86.91%,Test 2中MRE为1.41 mm,2 mm SDR为77.16%。Chen等^[37]引入注意力特征金字塔模块来提取语义增强的融合特征,在ISBI2015公共数据集上测试,Test 1中MRE为 (1.17 ± 1.19) mm,2 mm SDR为86.67%,Test 2中MRE为 (1.48 ± 0.77) mm,2 mm SDR为75.05%,虽然精确度未有显著提高,但也提供了一种新思路。Oh等^[38]采用深度解剖上下文特征学习方法来学习头颅侧位片更深层次的语义特征并提高定位精度,在ISBI2015公共数据集上测试,Test 1中2 mm SDR为86.2%,Test 2中为75.89%,相较于Chen等^[37]的方法,该算法还可用于3D图像任务。Qian等^[39]提出一种新的多头神经网络CephaNN,基于多头注意机制,先使用多头结构计算两组特征,然后根据特征计算注意力权重,连接加权的特征来估计标志点的热图,在ISBI2015公共数据集上测试,Test 1中MRE为1.15 mm,2 mm SDR为87.61%,Test 2中MRE为1.43 mm,2 mm SDR为76.32%。Zhu等^[40]研究了“You Only Learn Once (YOLO)”的思想,开发了一个由局部网络和全局网络组成的通用解剖标志检测模型,其中局部网络基于U-Net构建,学习多域局部特征,输出标志点热图,全局网络提取全局特征并减少模糊性,对头颅侧位片、手掌、胸片3个数据集进行检测,都取得了不错的效果,在ISBI2015数据集上,MRE为 (1.54 ± 2.37) mm,2 mm SDR为77.79%。Wang等^[41]进一步提出一种基于两阶段热图回归的高效稳定的方法,先采用HR-Net^[42]从高分辨率图像并行输出多尺度特征图并提炼,而后利用改进的热图解码方法进行精确定位,在ISBI2015公共数据集上测试,Test 1中MRE为1.09 mm,2 mm SDR为88.98%,Test 2中MRE为1.33 mm,2 mm SDR为78.68%。针对鲁棒性问题,Jiang等^[43]构建了一个级联框架,第一阶段检测10个ROI,每个区域包含1~9个标志点,第二阶段精确定位ROI中的标志点。最终在20个中

心的9 870张侧位片测试中, 30个标志点的MRE为(0.94±0.74) mm, 2 mm SDR达到91.73%。

2.6.4 其他 Lu等^[44]提出基于多尺度图像块的图卷积网络(graph convolutional network, GCN)框架, 该框架由多尺度图像采样、空间化特征生成和用于坐标解码的3层GCN组成。首先从高斯金字塔中分层采样具有相同大小的图像块, 而后堆叠这些图像块提取代表性特征, 然后结合注意力模块生成包含局部外观特征和形状信息的空间化特征并将其输入3层GCN中, 在ISBI2015公共数据集上测试, Test 1中MRE为1.06 mm, 2 mm SDR为87.93%, Test 2中MRE为1.37 mm, 2 mm SDR为76.11%。

2.6.5 优缺点分析 目前, 以区域提议为主的检测模式表现不佳, 现阶段已较少应用。以坐标回归为主的模式展示出了整合标志点结构知识的潜力, 然而对结构知识的利用仍然不足, 从而限制了其性能。通过标志点之间的信息交换以促进检测的方法仍有待探索。以热图回归为主的模式受到了学者们的青睐。该模式利用热图的空间泛化

能力来学习标志点之间的位置关系, 通常首先生成标志点的热图, 然后逐步细化以确定标志点位置。虽然这个过程较为烦琐, 但结果通常更为稳定。在ISBI 2015公开数据集上, Wang等^[41]通过控制图像分辨率, 获得了优秀的结果, 2 mm内SDR达到88.98%。这种模式对图像分辨率要求较高, 且在采样过程中由于分辨率降低会导致解码错误问题, 这些因素限制了该模型的性能。相较于ML算法, DL算法在精确度上有了显著提升, 其方法也更为复杂和多样化, 然而在ISBI2015公共数据集上, 2 mm SDR仍未能突破90%。学者们尝试从不同角度去提高精确度, 但往往局限于单一模型。未来开发一种能集成多种高精度模型的集成学习算法可能成为重要的研究方向。此外, 现有数据集来源较为单一, 数据量的缺乏是导致精确度和稳定性不高的一个重要原因。通过扩大真实数据集的规模, 收集多中心数据等方式, 可能进一步提高算法的精确度、稳定性和泛化能力。

二维头影自动定点各类方法内容摘要见表1。

表 1 二维头影测量自动定点方法摘要

Tab 1 The abstract of two-dimensional cephalometric automatic landmarking

定点方法	参考文献	样本量	标志点数量	自动定点误差
基于知识的方法	[15]	测试样本: 2张X线片	36	定位23个标志点, 具体不详
	[16]	测试样本: 5张X线片	27	9个标志点平均误差2.06 mm, 误差<1 mm者占18%, <2 mm占58%
	[17]	训练样本: 28张X线片 测试样本: 58张X线片	4	鼻腔区域3个标志点平均误差约4.5 mm 颅骨中部区域1个标志点平均误差约3 mm
基于模型的方法	[18]	训练样本: 63张X线片 测试样本: 63张X线片	16	误差<1 mm者占13%, <2 mm占35%, <5 mm占74%
	[19]	训练样本: 60张X线片 测试样本: 60张X线片	17	平均误差1.68 mm
	[21]	训练样本: 40张X线片 测试样本: 40张X线片	20	2 mm内识别率平均为85%
基于模板匹配的方法	[22]	训练样本: 20张X线片 测试样本: 20张X线片	17	平均误差1.1 mm, 2 mm内检出率平均为90.3%
	[23]	训练样本: 150张X线片 测试样本: 150张X线片	19	MRE为(1.67±1.65) mm, 2 mm SDR为74.95%
基于ML的方法	[24]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	2 mm SDR为80.21%
	[25]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: 2 mm SDR为75.37% Test 2: 2 mm SDR为67.68%
基于DL的方法	[26]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: 2 mm SDR为82.5% Test 2: 2 mm SDR为72.4%
	[27]	训练样本: 150张X线片 测试样本: 250张X线片	19	2 mm SDR约38%, 4 mm SDR约80%

续表				
定点方法	参考文献	样本量	标志点数量	自动定点误差
坐标回归	[28]	训练样本: 150张X线片 测试样本: 150张X线片	19	效果一般
	[29]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为(1.01±0.85) mm, 2 mm SDR为88.32% Test 2: MRE为(1.33±0.74) mm, 2 mm SDR为77.05%
	[30]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为1.04 mm, 2 mm SDR为88.49%, Test 2: MRE为1.43 mm, 2 mm SDR为76.57%
	[31]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为(1.34±0.92) mm, 2 mm SDR为81.37% Test 2: MRE为(1.64±0.91) mm, 2 mm SDR为70.58%
	[32]	训练样本: 150张X线片 测试样本: 250张X线片	19	2 mm SDR为73.33%
	[33]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为(1.12±0.88) mm, 2 mm SDR为86.91% Test 2: MRE为(1.42±0.84) mm, 2 mm SDR为86.06%
	[35]	训练样本: 3 150张X线片 测试样本: 100张X线片	20	MRE为(1.36±0.98) mm
	[36]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为1.12 mm, 2 mm SDR为86.91% Test 2: MRE为1.41 mm, 2 mm SDR为77.16%
热图回归	[37]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为(1.17±1.19) mm, 2 mm SDR为86.67% Test 2: MRE为(1.48±0.77) mm, 2 mm SDR为75.05%
	[38]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: 2 mm SDR为86.2% Test 2: 2 mm SDR为75.89%
	[39]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为1.15 mm, 2 mm SDR为87.61% Test 2: MRE为1.43 mm, 2 mm SDR为76.32%
	[40]	训练样本: 150张X线片 测试样本: 250张X线片	19	MRE为(1.54±2.37) mm, 2 mm SDR为77.79%
	[41]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为1.09 mm, 2 mm SDR为88.98% Test 2: MRE为1.33 mm, 2 mm SDR为78.68%
	[43]	训练样本: 9 870张X线片 测试样本: 9 870张X线片	30	MRE为(0.94±0.74) mm, 2 mm SDR为91.73%
	[44]	训练样本: 150张X线片 测试样本1: 150张X线片 测试样本2: 100张X线片	19	Test 1: MRE为1.06 mm, 2 mm SDR为87.93% Test 2: MRE为1.37 mm, 2 mm SDR为76.11%

3 CBCT自动定点

3.1 基于知识的方法

基于知识的方法指根据预先确定的定义,在图像的解剖轮廓上定位标志点,由于解剖标志的生物几何形状多变且复杂,不同于已知的几何形状或表面,检测时易出现误差。Gupta等^[45]提出了一种基于知识的CBCT图像标志点自动检测算法,将相邻的标志点分组,并通过感兴趣体积(vo-

lume of interest, VOI)提取检测,20个标志点的总平均误差为(2.01±1.23) mm,2 mm SDR为64.67%,用时126.25 s。Neelapu等^[46]提出了一种基于人体解剖学边界定义的CBCT图像标志点自动检测算法,将正中矢状面分为4个象限,在解剖轮廓上自动检测20个标志点,总体平均误差为(1.88±1.10) mm,2 mm SDR为64.16%。

3.2 基于模型的方法

基于模型的方法依靠特征提取的参考模型系统,与全体积分析相比计算更快,但易受图像质

量的影响,尤其是戴矫治器患者的图像中存在的金属伪影会显著降低图像质量,进而降低检测的精确度。一些标志点如外耳道上点、蝶鞍点,由于其解剖形状不规则和位置变异,也难以精确定位。Shahidi等^[47]结合了基于特征(主轴配准)和基于体素相似度的图像配准方法,采用8个患者的CBCT图像建立参考图像集,通过缩放、旋转和平移测试图像完成配准,最后转移标志点完成定点,14个标志点的平均误差为3.40 mm,3 mm SDR为63.57%。Montúfar等^[48]结合基于模型和学习的方法,使用CBCT的数字重建X线片进行建模,用冠状位和矢状位投影训练2个主动形状模型,18个标志点的平均误差为 (3.64 ± 1.43) mm。Montúfar等^[49]进一步应用基于知识的方法改进和调整标志点定位,最终18个标志点平均误差为 (2.51 ± 1.61) mm,用时49 s。结合模型和知识的方法明显优于单一方法,但精确度仍不高,由于颅颌面结构的变化,每个数据集的几何形状和结构都是独一无二的,使得基于模型的方法难以在临床得到推广。

3.3 基于ML的方法

基于ML的方法,通常从局部图像块中提取特征来训练分类器。为了解决由患者之间的形态学变化及CBCT图像伪影所带来的问题,Zhang等^[50]提出了基于分割引导的部分联合回归森林模型和多尺度统计特征的自动定点方法。首先通过回归投票策略,聚合上下文位置的证据,解决标志点附近的图像伪影问题;然后分割CBCT图像中的上下颌骨,去除患者间形态变化引起的无信息体素;最后利用部分联合模型来精准定位;结果发现15个标志点的误差均在2 mm以内。CBCT作为一种高维数据,处理起来相对困难,为此Lee等^[51]提出了一种基于阴影二维图像的方法,对使用不同照明角度和各种视角的二维标记图像数据进行训练,形成立体颅面形态结构,显著减少了输入数据的大小。该测试技术对7个主要标志点三维方向平均误差为1.80 mm,1 mm SDR为85.7%。基于ML的方法精确度大大提高,但处理的标志点较少,偏倚风险较高,增加标志点后准确率或有一定程度下降,限制了其临床应用。

3.4 基于DL的方法

3.4.1 区域提议分类 这种模式首先通过区域提议网络生成多个区域,然后在多任务学习框架中联合输出目标的位置、类别和分割,如Mask R-CNN^[52]。Lang等^[53]利用Mask R-CNN,结合损失函数,提出一种分三步从粗到精的方法。在第一阶段,使用下

采样的3D图像训练一个简单的网络,输出每个标志点的粗位置;在第二和第三阶段,分别使用从中分辨率和高分辨率3D图像中采样的补丁来训练网络,在第一阶段估计的标志点位置周围来细化位置。对49个CBCT的105个标志点平均检测误差为 (1.75 ± 0.91) mm,测试时间为20 min。Ahn等^[54]将面部轮廓分析算法与DL模型相结合,通过提取面部轮廓并应用Mask R-CNN来分区和检测ROI,对13个参数的检测与专家相比无明显差异,所用时间从30 min缩短到约30 s。Lang等^[55]对之前的研究^[53]进行优化,简化训练过程,稳定检测结果。首先使用下采样图像训练初始浅层网络,利用全局解剖信息粗略预测位置;然后在粗略的标志周围裁剪1组中高分辨率的图像块,用于训练另外2个检测网络,并利用局部外观进一步细化;此外还学习局部标志依赖性作为辅助指导精确定位;最终105个标志点的平均误差为 (1.38 ± 0.95) mm,用时不到4 min。

3.4.2 热图回归 Payer等^[32]将标志点定位表述为热图回归问题,通过将局部外观和空间配置信息组合到单个端到端训练网络中进行定位。Zhang等^[56]采用2个基于U-Net架构的全卷积网络(fully convolutional network, FCN)来检测多个解剖标志,其中第1个FCN预测从每个体素到目标标志的3D位移,第2个FCN将3D位移与输入图像块相结合以回归标志热图,结果发现15个标志点平均精度为 (1.10 ± 0.71) mm,但由于内存消耗巨大,无法处理更大规模的标志点定位,而且仅使用图像块可能会导致误检,从而忽略整个图像的全局解剖信息。Chen等^[57]提出一种基于3D Faster R-CNN的颅颌面标志自动检测方法,第一阶段使用3D Faster R-CNN粗略估计标志点位置,第二阶段采用轻量级多尺度U-Net(MS U-Net)通过热图回归细化标志点位置,测量18个标志点的平均误差为 (0.89 ± 0.64) mm,用时26.2 s。这些研究的标志点较少,存在较高的偏倚风险,鲁棒性和泛化能力值得关注。为此,Dot等^[58]设计了一种基于空间结构网络(spatial configuration net, SCN)的由粗到精的方法,在198个CBCT数据集的33个标志点中,平均定位误差为 (1.0 ± 1.3) mm,2 mm SDR为90.4%,耗时约1 min。

3.4.3 其他 Huang等^[59]提出一种通过将CBCT合成二维头颅侧位片的方法。首先对CBCT图像进行基于sigmoid的转换合成侧位片,然后设计像素-像素生成对抗网络,从2个CBCT投影合成侧位片,通过超分辨率DL技术将两者合成,进一步提高图

像质量再进行定点。在ISBI2015数据集中, Test 1 的2 mm SDR为86.7%。Blum等^[60]提出一种三阶段算法, 每个阶段都建立在3D U-Net算法的相同架构上, 通过多次缩放, 首先确定标志点的粗略位置, 然后在其后的2个阶段中细化, 对35个标志点的定位与专家相比无明显差异, 但仅耗时15 s, 远少于专家用时。针对伦理医疗数据使用的限制, Yun等^[61]提出一种去除配对CT图像的利用匿名标志点数据集半监督方法, 利用变分自动编码器, 仅使用15组配对训练数据, 对90个标志点进行检测, 平均误差为2.88 mm。Chen等^[62]提出一种新的结构感知长短期记忆框架。首先通过热图回归在

下采样的CBCT上粗略定位标志点, 然后基于标志点周围裁剪的多分辨率图像块通过关注偏移回归逐步细化标志点位置。使用该方法在内部数据集及公共数据集上分别测试, 17个标志点的MRE分别为(1.64±1.13) mm和(2.37±1.60) mm, 2 mm SDR分别为74.28%和56.36%, 测试时间分别为0.46 s和0.27 s。Torres等^[63]提出一个在三维人脸模型中自动定位头影测量标志点的框架。先创建代表3D模型的二维图像, 然后通过回归CNN检测标志点。在3个不同的3D人脸模型数据集上进行评估, 标志点的平均距离误差分别为2.3、3.0和3.2 mm。三维头影测量自动定点方法内容摘要见表2。

表 2 三维头影测量自动定点方法摘要

Tab 2 The abstract of three-dimensional cephalometric automatic landmarking

定点方法	参考文献	样本量	标志点数量	自动定点误差
基于知识的方法	[45]	测试样本: 30例 CBCT	20	总平均误差为 (2.01±1.23) mm, 2 mm SDR 为 64.67%
	[46]	测试样本: 30例 CBCT	20	总体平均误差为 (1.88±1.10) mm, 2 mm SDR 为 64.16%
基于模型的方法	[47]	训练样本: 8例 CBCT 测试样本: 20例 CBCT	14	平均误差为 3.40 mm, 3 mm SDR 为 63.57%
	[48]	训练样本: 24 例 CBCT 测试样本: 24 例 CBCT	18	平均误差为 (3.64±1.43) mm
	[49]	训练样本: 24 例 CBCT 测试样本: 24 例 CBCT	18	平均误差为 (2.51±1.61) mm
	[50]	训练样本: 41 例 CBCT, 30 例多层螺旋 CT 测试样本: 41 例 CBCT	15	平均误差为 1.44 mm
基于 ML 的方法	[51]	训练样本: 20 例 CT 测试样本: 7 例 CT	7	x 轴: 0.49 mm, y 轴: 1.02 mm, z 轴: 1.40 mm, 平均误差 1.80 mm
基于 DL 的方法				
区域提议分类	[53]	训练样本: 39 例 CBCT 测试样本: 10 例 CBCT	105	平均误差为 (1.75±0.91) mm
	[54]	训练样本: 170 例 CBCT 测试样本: 30 例 CBCT	13	精确度与专家无异
	[55]	训练样本: 39 例 CBCT 测试样本: 10 例 CBCT	105	平均误差为 (1.38±0.95) mm
热图回归	[56]	训练与测试样本: 77 例 CBCT, 5 折交叉验证 额外训练样本: 30 例 CT	15	平均误差为 (1.10±0.71) mm
	[57]	训练样本: 60 例 CBCT 测试样本: 80 例 CBCT	18	平均误差为 (0.89±0.64) mm
	[58]	训练样本: 160 例 CT 测试样本: 38 例 CT	33	平均误差为 (1.0±1.3) mm, 2 mm SDR 为 90.4%
其他	[59]	训练样本: 150 张 X 线片 测试样本 1: 150 张 X 线片 测试样本 2: 100 张 X 线片	19	Test1: 2 mm SDR 为 86.7% Test2: 2 mm SDR 为 73.7%
	[60]	训练样本: 930 例 CBCT 测试样本: 115 例 CBCT	35	平均误差为 2.73 mm
	[61]	测试样本: 24 组成对数据 (CT 图像和标志点坐标) 和 229 个匿名标志点数据	90	平均误差为 2.88 mm
	[62]	1) 内部数据集: 89 例 CBCT 2) 公开数据集 PDDCA: 48 例 CT	17	内部数据集: MRE 为 (1.64±1.13) mm, 2 mm SDR 为 74.28% 公开数据集: MRE 为 (2.37±1.60) mm, 2 mm SDR 为 56.36%

总体来说, DL算法优于ML算法, 但仍然存在一些问题。如何提高多标志点的精确度, 如何减少运算时间, 如何增加数据量等问题急需解决。

4 结语

经过几十年的发展, AI在头颅侧位片自动定点上的算法已逐渐趋于成熟, 特别是基于DL的方法, 其2 mm内精确度已接近90%, 然而该领域仍面临一些挑战。1) 由于医学行业的特殊性, 加上患者隐私和医疗机构资源竞争等因素, 可共享的数据较少。目前研究中常用的ISBI2015公开数据集^[14]仅包括400张头颅侧位X线片, 限制了模型的稳定性和泛化能力。尽管研究人员可以通过数据增强手段扩大数据集, 但易造成过拟合。2) 缺少多中心数据。单中心数据的偏差不利于临床的广泛推广。3) 许多AI算法因其“黑箱”特性缺乏明确的可解释参数, 难以保证性能的一致性, 这使得它们在临床应用过程中的透明度和安全性受到质疑^[64]。此外, 基于CBCT的自动定点算法仍不成熟, 标志点检测的数量、精度和速度仍有较大提升空间, 主要原因是样本数量有限, 且缺乏相应CBCT三维头影测量指标标准^[65]及误差评判标准。尽管基于热图回归的DL算法精确度不错, 但在处理大量的三维数据时耗时较长, 特别是当标志点数量增多时, 测量结果的精确度可能下降, 测量时间也会相应增加。

为提高精度和缩短测量时间, 未来研究方向可以考虑以下几点。1) 构建更符合临床要求的标志点数据集, 扩大真实数据集, 解决样本量不足的问题。2) 收集多中心数据, 减少不同中心硬件差异造成的误差, 提高模型泛化能力。3) 提升硬件水平, 提高成像质量, 增强数据处理能力。4) 开发新的自动定点算法, 尤其是针对三维影像, 采用新一代的DL方法, 如Vision Transformer技术等^[66]。5) 采用可视觉解释、文本解释以及基于实例的解释等方式增强算法模型的可解释性^[67]。可以预见, 随着大数据的积累、算法的改进和计算能力的提高, 头影测量自动定点的技术将取得更大的进步。

利益冲突声明: 作者声明本文无利益冲突。

5 参考文献

- [1] Broadbent B. A new X-ray technique and its application to orthodontia[J]. *Angle Orthod*, 2009, 1: 45-66.
- [2] Yao J, Zeng W, He T, et al. Automatic localization of cephalometric landmarks based on convolutional neural network[J]. *Am J Orthod Dentofacial Orthop*, 2022, 161(3): e250-e259.
- [3] Mahto RK, Kafle D, Giri A, et al. Evaluation of fully automated cephalometric measurements obtained from web-based artificial intelligence driven platform[J]. *BMC Oral Health*, 2022, 22(1): 132.
- [4] Duran GS, Gökmen Ş, Topsakal KG, et al. Evaluation of the accuracy of fully automatic cephalometric analysis software with artificial intelligence algorithm[J]. *Orthod Craniofac Res*, 2023, 26(3): 481-490.
- [5] Panesar S, Zhao A, Hollensbe E, et al. Precision and accuracy assessment of cephalometric analyses performed by deep learning artificial intelligence with and without human augmentation[J]. *Appl Sci*, 2023, 13(12): 6921.
- [6] Indermun S, Shaik S, Nyirenda C, et al. Human examination and artificial intelligence in cephalometric landmark detection—is AI ready to take over[J]. *Dentomaxillofac Radiol*, 2023, 52(6): 20220362.
- [7] Rajaraman V. JohnMcCarthy—father of artificial intelligence[J]. *Resonance*, 2014, 19(3): 198-207.
- [8] Kiełczykowski M, Kamiński K, Perkowski K, et al. Application of artificial intelligence (AI) in a cephalometric analysis: a narrative review[J]. *Diagnostics*, 2023, 13(16): 2640.
- [9] Wang HC, Fu TF, Du YQ, et al. Scientific discovery in the age of artificial intelligence[J]. *Nature*, 2023, 620(7972): 47-60.
- [10] Hosny A, Parmar C, Quackenbush J, et al. Artificial intelligence in radiology[J]. *Nat Rev Cancer*, 2018, 18(8): 500-510.
- [11] Yasaka K, Akai H, Kunimatsu A, et al. Deep learning with convolutional neural network in radiology [J]. *Jpn J Radiol*, 2018, 36(4): 257-272.
- [12] Schwendicke F, Chaurasia A, Arsiwala L, et al. Deep learning for cephalometric landmark detection: systematic review and meta-analysis[J]. *Clin Oral Investig*, 2021, 25(7): 4299-4309.
- [13] Schwendicke F, Golla T, Dreher M, et al. Convolutional neural networks for dental image diagnostics:

- a scoping review[J]. *J Dent*, 2019, 91: 103226.
- [14] Wang CW, Huang CT, Lee JH, et al. A benchmark for comparison of dental radiography analysis algorithms[J]. *Med Image Anal*, 2016, 31: 63-76.
- [15] Lévy-Mandel AD, Venetsanopoulos AN, Tsotsos JK. Knowledge-based landmarking of cephalograms[J]. *Comput Biomed Res*, 1986, 19(3): 282-309.
- [16] Parthasarathy S, Nugent ST, Gregson PG, et al. Automatic landmarking of cephalograms[J]. *Comput Biomed Res*, 1989, 22(3): 248-269.
- [17] Desvignes M, Romaniuk B, Clouard R, et al. First steps toward automatic location of landmarks on X-ray images[C/OL]//*Proceedings 15th International Conference on Pattern Recognition. ICPR-2000. Barcelona, Spain: IEEE, 2000: 275-278. https://ieeexplore.ieee.org/document/906066.*
- [18] Hutton TJ, Cunningham S, Hammond P. An evaluation of active shape models for the automatic identification of cephalometric landmarks[J]. *Eur J Orthod*, 2000, 22(5): 499-508.
- [19] Vucinić P, Trpovski Z, Šćepan I. Automatic landmarking of cephalograms using active appearance models[J]. *Eur J Orthod*, 2010, 32(3): 233-241.
- [20] Kaur A, Singh C. Automatic cephalometric landmark detection using Zernike moments and template matching[J]. *Signal Image Video Process*, 2015, 9(1): 117-132.
- [21] Cardillo J, Sid-Ahmed MA. An image processing system for locating craniofacial landmarks[J]. *IEEE Trans Med Imaging*, 1994, 13(2): 275-289.
- [22] Grau V, Alcañiz M, Juan MC, et al. Automatic localization of cephalometric landmarks[J]. *J Biomed Inform*, 2001, 34(3): 146-156.
- [23] Lindner C, Wang CW, Huang CT, et al. Fully automatic system for accurate localisation and analysis of cephalometric landmarks in lateral cephalograms[J]. *Sci Rep*, 2016, 6: 33581.
- [24] Urschler M, Ebner T, Štern D. Integrating geometric configuration and appearance information into a unified framework for anatomical landmark localization[J]. *Med Image Anal*, 2018, 43: 23-36.
- [25] Arik SÖ, Ibragimov B, Xing L. Fully automated quantitative cephalometry using convolutional neural networks[J]. *J Med Imaging*, 2017, 4(1): 014501.
- [26] Qian JH, Cheng M, Tao YB, et al. CephaNet: an improved faster R-CNN for cephalometric landmark detection[C/OL]//2019 IEEE 16th International Symposium on Biomedical Imaging (ISBI 2019). Venice, Italy: IEEE, 2019: 868-871. <https://doi.org/10.1109/ISBI.2019.8759437>.
- [27] Dai XB, Zhao H, Liu TL, et al. Locating anatomical landmarks on 2D lateral cephalograms through adversarial encoder-decoder networks[J]. *IEEE Access*, 2019, 7: 132738-132747.
- [28] Lee H, Park M, Kim J. Cephalometric landmark detection in dental X-ray images using convolutional neural networks[C/OL]//*Medical imaging 2017: computer-aided diagnosis. Orlando, United States: SPIE, 2017: 494-499. https://www.spiedigitallibrary.org/conference-proceedings-of-spie/10134/01341W/Cephalometric-landmark-detection-in-dental-x-ray-images-using-convolutional/10.1117/12.2255870.full.*
- [29] Gilmour L, Ray N. Locating cephalometric X-ray landmarks with foveated pyramid attention[EB/OL]. arXiv: 2008.04428. <http://arxiv.org/abs/2008.04428>.
- [30] Li WJ, Lu YH, Zheng K, et al. Structured landmark detection via topology-adapting deep graph learning[C]//*European Conference on Computer Vision. Cham: Springer, 2020: 266-283.*
- [31] Zeng MM, Yan ZL, Liu S, et al. Cascaded convolutional networks for automatic cephalometric landmark detection[J]. *Med Image Anal*, 2021, 68: 101904.
- [32] Payer C, Štern D, Bischof H, et al. Integrating spatial configuration into heatmap regression based CNNs for landmark localization[J]. *Med Image Anal*, 2019, 54: 207-219.
- [33] Zhong Z, Li J, Zhang Z, et al. An attention-guided deep regression model for landmark detection in cephalograms[C/OL]//Shen D, Liu T, Peters TM, et al. *Medical image computing and computer assisted intervention—MICCAI 2019. Cham: Springer International Publishing, 2019: 540-548. https://doi.org/10.1007/978-3-030-32226-7_60.*
- [34] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C/OL]//Navab N, Hornegger J, Wells WM, et al.

- Medical image computing and computer-assisted intervention-MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241. https://doi.org/10.1007/978-3-319-24574-4_28.
- [35] Kim J, Kim I, Kim YJ, et al. Accuracy of automated identification of lateral cephalometric landmarks using cascade convolutional neural networks on lateral cephalograms from nationwide multi-centres [J]. *Orthod Craniofac Res*, 2021, 24(Suppl 2): 59-67.
- [36] Kwon HJ, Koo HI, Park J, et al. Multistage probabilistic approach for the localization of cephalometric landmarks[J]. *IEEE Access*, 2021, 9: 21306-21314.
- [37] Chen R, Ma Y, Chen N, et al. Cephalometric landmark detection by attentive feature pyramid fusion and regression-voting[C/OL]//Shen D, Liu T, Peters TM, et al. Medical image computing and computer assisted intervention-MICCAI 2019. Cham: Springer International Publishing, 2019: 873-881. https://doi.org/10.1007/978-3-030-32248-9_97.
- [38] Oh K, Oh IS, Le VNT, et al. Deep anatomical context feature learning for cephalometric landmark detection[J]. *IEEE J Biomed Health Inform*, 2021, 25(3): 806-817.
- [39] Qian JH, Luo WZ, Cheng M, et al. CephaNN: a multi-head attention network for cephalometric landmark detection[J]. *IEEE Access*, 2020, 8: 112633-112641.
- [40] Zhu H, YAO Q, XIAO L, et al. You only learn once: universal anatomical landmark detection[C/OL]//de Bruijne M, Cattin PC, Cotin S, et al. Medical image computing and computer assisted intervention-MICCAI 2021. Cham: Springer International Publishing, 2021: 85-95.
- [41] Wang XL, Rigall E, Chen QM, et al. Efficient and stable cephalometric landmark localization using two-stage heatmaps' regression[J]. *IEEE Trans Instrum Meas*, 2022, 71: 2518816.
- [42] Sun K, Xiao B, Liu D, et al. Deep high-resolution representation learning for human pose estimation [C/OL]//2019 IEEE/CVF conference on computer vision and pattern recognition (CVPR). Long Beach, USA: IEEE, 2019: 5686-5696.
- [43] Jiang FL, Guo YT, Yang C, et al. Artificial intelligence system for automated landmark localization and analysis of cephalometry[J]. *Dentomaxillofac Radiol*, 2023, 52(1): 20220081.
- [44] Lu G, Zhang YX, Kong YY, et al. Landmark localization for cephalometric analysis using multiscale image patch-based graph convolutional networks[J]. *IEEE J Biomed Health Inform*, 2022, 26(7): 3015-3024.
- [45] Gupta A, Kharbanda OP, Sardana V, et al. A knowledge-based algorithm for automatic detection of cephalometric landmarks on CBCT images[J]. *Int J Comput Assist Radiol Surg*, 2015, 10(11): 1737-1752.
- [46] Neelapu BC, Kharbanda OP, Sardana V, et al. Automatic localization of three-dimensional cephalometric landmarks on CBCT images by extracting symmetry features of the skull[J]. *Dentomaxillofac Radiol*, 2018, 47(2): 20170054.
- [47] Shahidi S, Bahrapour E, Soltanimehr E, et al. The accuracy of a designed software for automated localization of craniofacial landmarks on CBCT images [J]. *BMC Med Imaging*, 2014, 14: 32.
- [48] Montúfar J, Romero M, Scougall-Vilchis RJ. Automatic 3-dimensional cephalometric landmarking based on active shape models in related projections [J]. *Am J Orthod Dentofacial Orthop*, 2018, 153(3): 449-458.
- [49] Montúfar J, Romero M, Scougall-Vilchis RJ. Hybrid approach for automatic cephalometric landmark annotation on cone-beam computed tomography volumes[J]. *Am J Orthod Dentofacial Orthop*, 2018, 154(1): 140-150.
- [50] Zhang J, Liu MX, Shen DG. Detecting anatomical landmarks from limited medical imaging data using two-stage task-oriented deep neural networks[J]. *IEEE Trans Image Process*, 2017, 26(10): 4753-4764.
- [51] Lee SM, Kim HP, Jeon K, et al. Automatic 3D cephalometric annotation system using shadowed 2D image-based machine learning[J]. *Phys Med Biol*, 2019, 64(5): 055002.
- [52] He K, Gkioxari G, Dollár P, et al. Mask R-CNN[C/OL]//2017 IEEE international conference on computer vision (ICCV). Venice, Italy: IEEE, 2017: 2980-2988. <https://ieeexplore.ieee.org/abstract/document/8237584>.

- [53] Lang Y, Wang L, Yap PT, et al. Automatic detection of craniomaxillofacial anatomical landmarks on CBCT images using 3D mask R-CNN[C/OL]// Zhang D, Zhou L, Jie B, et al. International workshop on graph learning in medical imaging. Cham: Springer International Publishing, 2019: 130-137. https://doi.org/10.1007/978-3-030-35817-4_16.
- [54] Ahn J, Nguyen TP, Kim YJ, et al. Automated analysis of three-dimensional CBCT images taken in natural head position that combines facial profile processing and multiple deep-learning models[J]. Comput Methods Programs Biomed, 2022, 226: 107123.
- [55] Lang YK, Lian CF, Xiao DQ, et al. Localization of craniomaxillofacial landmarks on CBCT images using 3D mask R-CNN and local dependency learning[J]. IEEE Trans Med Imaging, 2022, 41(10): 2856-2866.
- [56] Zhang J, Liu M, Wang L, et al. Joint craniomaxillofacial bone segmentation and landmark digitization by context-guided fully convolutional networks[J]. Med Image Comput Comput Assist Interv, 2017, 10434: 720-728.
- [57] Chen XY, Lian CF, Deng HH, et al. Fast and accurate craniomaxillofacial landmark detection via 3D faster R-CNN[J]. IEEE Trans Med Imaging, 2021, 40(12): 3867-3878.
- [58] Dot G, Schouman T, Chang S, et al. Automatic 3-dimensional cephalometric landmarking via deep learning[J]. J Dent Res, 2022, 101(11): 1380-1387.
- [59] Huang YX, Fan FX, Syben C, et al. Cephalogram synthesis and landmark detection in dental cone-beam CT systems[J]. Med Image Anal, 2021, 70: 102028.
- [60] Blum FMS, Möhlhenrich SC, Raith S, et al. Evaluation of an artificial intelligence-based algorithm for automated localization of craniofacial landmarks[J]. Clin Oral Investig, 2023, 27(5): 2255-2265.
- [61] Yun HS, Hyun CM, Baek SH, et al. A semi-supervised learning approach for automated 3D cephalometric landmark identification using computed tomography[J]. PLoS One, 2022, 17(9): e0275114.
- [62] Chen RN, Ma YX, Chen NL, et al. Structure-aware long short-term memory network for 3D cephalometric landmark detection[J]. IEEE Trans Med Imaging, 2022, 41(7): 1791-1801.
- [63] Torres HR, Morais P, Fritze A, et al. 3D facial landmark localization for cephalometric analysis[C/OL]// 2022 44th annual international conference of the IEEE engineering in medicine & biology society (EMBC). Glasgow, United Kingdom: IEEE, 2022: 1016-1019. <https://doi.org/10.1109/EMBC48229.2022.98-71184>.
- [64] van der Velden BHM, Kuijff HJ, Gilhuijs KGA, et al. Explainable artificial intelligence (XAI) in deep learning-based medical image analysis[J]. Med Image Anal, 2022, 79: 102470.
- [65] 李媛, 秦金炜, 侯伟, 等. CBCT 三维头影测量常用指标的初步探索[J]. 口腔医学, 2021, 41(8): 720-723.
- Li Y, Qin JW, Hou W, et al. A preliminary study on the common indexes of the CBCT 3D cephalometric analysis[J]. Stomatology, 2021, 41(8): 720-723.
- [66] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale[EB/OL]//e-printsarXiv. arXiv: 2010.11929. <https://ui.adsabs.harvard.edu/abs/2020arXiv201011929D>.
- [67] Tjoa E, Guan CT. A survey on explainable artificial intelligence (XAI): toward medical XAI[J]. IEEE Trans Neural Netw Learn Syst, 2021, 32(11): 4793-4813.

(本文编辑 吴爱华)